TP Machine Learning – TD1, Exercice 2

Gradient descendant : régression linéaire et quadratique

Abir Abidi
Khairi Hammami

7 novembre 2026

Table des matières

1 Objectif du TP **2**

2 Prétraitement des données **2**

3 Partie 1 : Modèle linéaire **3**

3.1 Q1 : Modèle linéaire et calcul du gradient 3

3.2 Q2 : Choix des hyperparamètres 3

3.3 Q3 : Tableau de performance 4

3.4 Q4 : Performance en fonction de alpha 4

3.5 Q5 : Performance selon le nombre d'itérations 6

3.6 Q6 : Ajout de niveaux aux hyperparamètres 6

3.7 Q7 : Anomalie du prétraitement 8

3.8 Q8 : Nouvelle initialisation 8

4 Partie 2 : Modèle quadratique **9**

4.1 Q9 : Matrice du modèle quadratique 9

4.2 Q10 : Initialisation des paramètres 9

4.3 Q11 : Performance du modèle quadratique 9

4.4 Q12 : Comparaison des modèles selon alpha 10

4.5 Q13 : Comparaison selon le nombre d'itérations 10

5 Remarques et observations **11**

6 Conclusion **12**

1 Objectif du TP

L'objectif de ce TP est d'implémenter l'algorithme du gradient descendant pour estimer les paramètres de deux modèles de régression : un modèle linéaire et un modèle quadratique.

Les données utilisées concernent le prix des voitures en fonction de trois variables :

— x_1 : l'âge de la voiture ;
— x_2 : la puissance ;
— x_3 : le kilométrage.

On étudie l'influence de deux hyperparamètres : le taux d'apprentissage α et le nombre d'itérations.

La mise à jour des paramètres est donnée par :

$$\theta \leftarrow \theta - \frac{\alpha}{m} X^T (X\theta - y)$$

La performance est évaluée avec deux mesures :

— MAE : erreur moyenne absolue ;
— MSE : erreur quadratique moyenne.

2 Prétraitement des données

Les données utilisées sont :

$$age = [60, 48, 12, 30]$$

$$puissance = [4, 7, 4, 5]$$

$$km = [110, 90, 20, 45]$$

Les valeurs de la variable cible sont :

$$y = [22, 31, 45, 43]$$

On divise les valeurs de y par 100 :

$$y_{\text{normalisé}} = \frac{y}{100}$$

Ainsi :

$$y = \begin{bmatrix} 0.22 \\ 0.31 \\ 0.45 \\ 0.43 \end{bmatrix}$$

Cette transformation permet de travailler avec des valeurs plus petites et de rapprocher l'échelle de la variable cible de celle des variables explicatives.

Les variables explicatives sont également divisées par des constantes fixes :

$$x_1 = \frac{age}{100}, \qquad x_3 = \frac{km}{150}$$

3 Partie 1 : Modèle linéaire

Le premier modèle utilisé est :

$$y = \theta_1 x_1 + \theta_2 x_3 + \theta_3$$

La matrice des variables explicatives est :

$$X_1 = \begin{bmatrix} 0.60 & 0.7333 & 1 \\ 0.48 & 0.6000 & 1 \\ 0.12 & 0.1333 & 1 \\ 0.30 & 0.3000 & 1 \end{bmatrix}$$

3.1 Q1 : Modèle linéaire et calcul du gradient

Les paramètres initiaux sont générés aléatoirement dans l'intervalle $[-0.7, 0.7]$:

$$\theta_0 \sim \mathcal{U}(-0.7, 0.7)$$

Le taux d'apprentissage utilisé est :

$$\alpha = 0.004$$

On effectue deux itérations du gradient descendant.

Les résultats obtenus par Python sont :

Itération	θ_1	θ_2	θ_3
1	-0.17607144	0.63047455	0.32405105
2	-0.17649720	0.62995125	0.32331512

L'initialisation aléatoire permet de tester l'apprentissage avec des valeurs initiales différentes des valeurs fixes utilisées auparavant.

3.2 Q2 : Choix des hyperparamètres

On utilise les valeurs suivantes du taux d'apprentissage :

$$\begin{aligned} \alpha = \{&0.001, 0.002, 0.004, 0.006, 0.008, \\ &0.01, 0.02, 0.03, 0.05, 0.07, \\ &0.1, 0.15, 0.2, 0.25, 0.3\} \end{aligned}$$

Le nombre d'itérations utilisé est :

$$N = \{100, 500, 1000, 5000, 10000\}$$

Ces valeurs permettent d'étudier plus précisément l'influence des hyperparamètres sur la convergence.

3.3 Q3 : Tableau de performance

On utilise les deux mesures suivantes :

Erreur moyenne absolue (MAE) :

$$MAE = \frac{1}{m} \sum_{i=1}^{m} |y_i - \hat{y}_i|$$

Erreur quadratique moyenne (MSE) :

$$MSE = \frac{1}{m} \sum_{i=1}^{m} (y_i - \hat{y}_i)^2$$

Les tableaux suivants présentent les résultats obtenus pour chaque combinaison d'hyperparamètres.

Tableau MAE :

TABLE 1 – MAE du modèle linéaire

Itérations \ α	.001	.002	.004	.006	.008	.01	.02	.03	.05	.07	.1	.15	.2	.25	.3
100	.8707	.7620	.5841	.4482	.3446	.2657	.1172	.1016	.0907	.0796	.0654	.0471	.0352	.0283	.0233
500	.5125	.2675	.1180	.1015	.0964	.0907	.0655	.0473	.0285	.0199	.0190	.0192	.0192	.0192	.0192
1000	.2678	.1181	.0964	.0851	.0747	.0655	.0354	.0235	.0190	.0192	.0192	.0192	.0192	.0191	.0191
5000	.0907	.0656	.0355	.0235	.0188	.0190	.0192	.0192	.0191	.0191	.0190	.0188	.0186	.0185	.0184
10000	.0656	.0355	.0188	.0191	.0192	.0192	.0192	.0191	.0190	.0188	.0186	.0184	.0181	.0179	.0178

Tableau MSE :

TABLE 2 – MSE du modèle linéaire

Itérations \ α	.001	.002	.004	.006	.008	.01	.02	.03	.05	.07	.1	.15	.2	.25	.3
100	.7588	.5820	.3444	.2063	.1260	.0794	.0184	.0130	.0099	.0077	.0053	.0029	.0017	.0010	.0007
500	.2669	.0804	.0187	.0130	.0113	.0099	.0053	.0029	.0011	.0006	.0004	.0004	.0004	.0004	.0004
1000	.0805	.0187	.0113	.0087	.0068	.0053	.0017	.0007	.0004	.0004	.0004	.0004	.0004	.0004	.0004
5000	.0099	.0053	.0017	.0007	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0004
10000	.0053	.0017	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0004	.0003	.0003	.0003

3.4 Q4 : Performance en fonction de alpha

Le graphique suivant représente l'évolution de la MAE en fonction du taux d'apprentissage pour les différents nombres d'itérations.

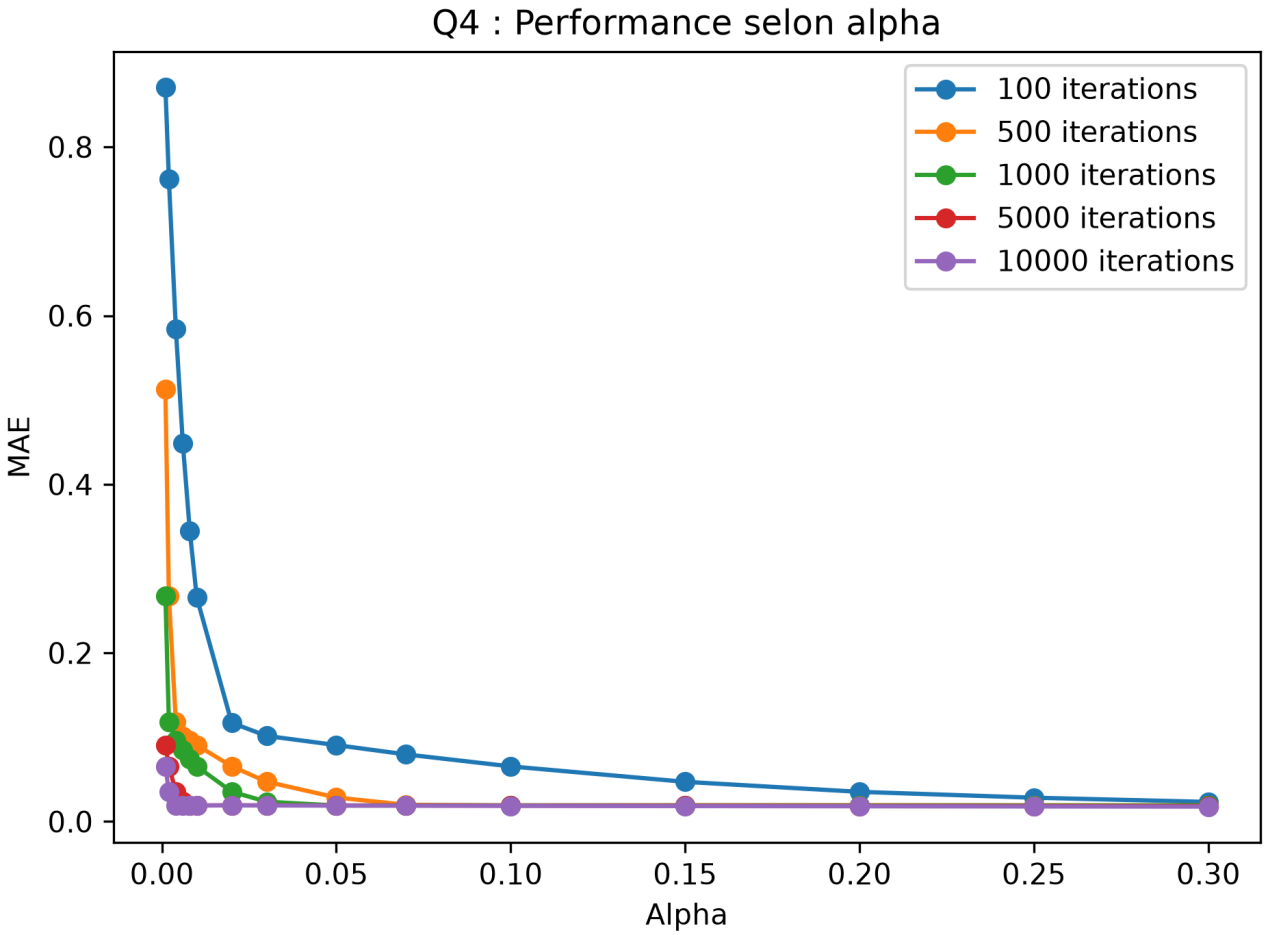


FIGURE 1 – Performance du modèle linéaire selon alpha

On observe que la MAE diminue généralement lorsque le taux d'apprentissage augmente.

Pour les petites valeurs d'alpha, l'apprentissage est lent. Les valeurs plus élevées permettent d'atteindre une meilleure performance plus rapidement.

3.5 Q5 : Performance selon le nombre d'itérations

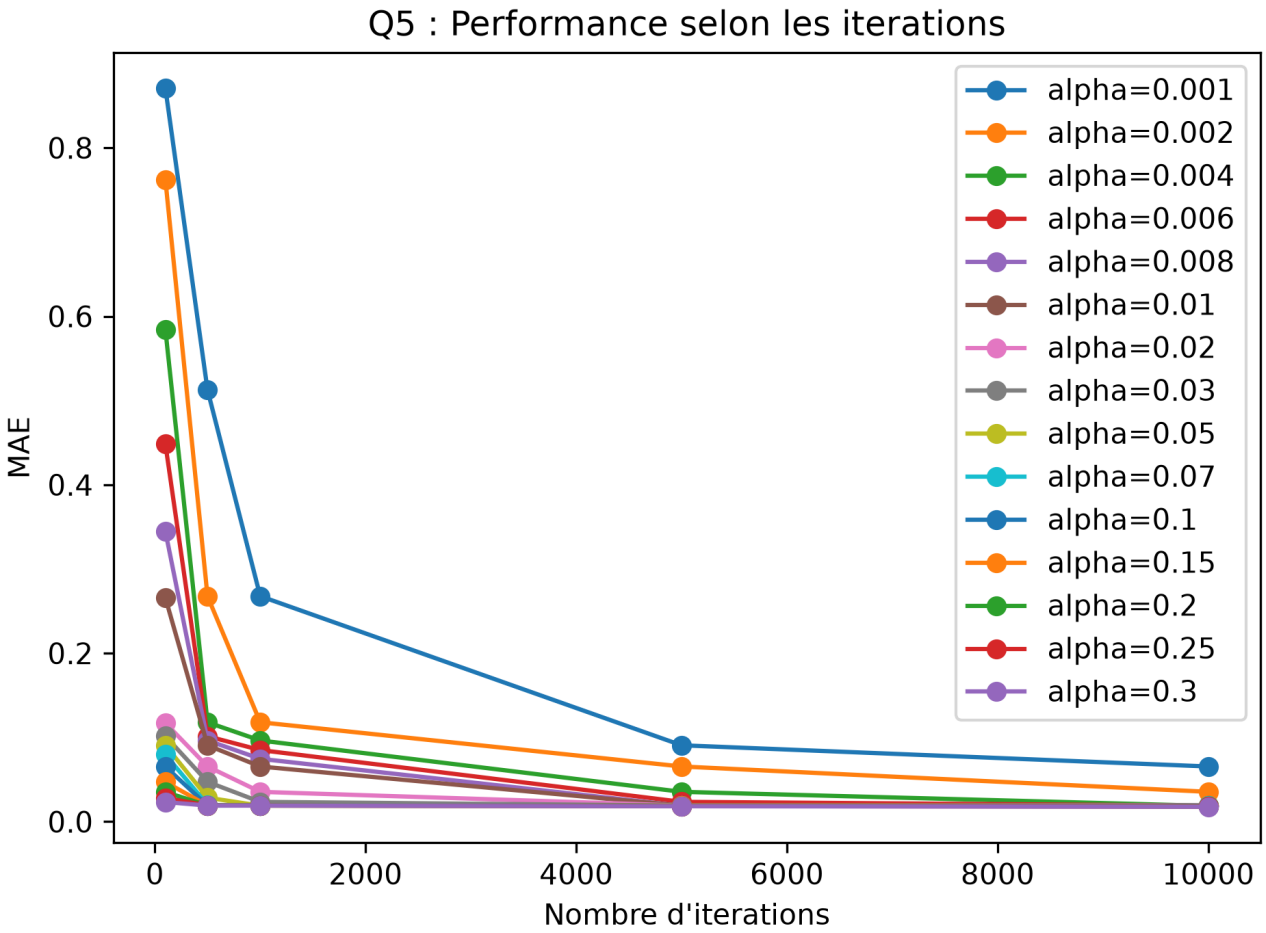


FIGURE 2 – Performance du modèle linéaire selon le nombre d'itérations

L'augmentation du nombre d'itérations permet généralement de réduire l'erreur jusqu'à atteindre une convergence.

Cependant, l'amélioration dépend également du taux d'apprentissage utilisé.

3.6 Q6 : Ajout de niveaux aux hyperparamètres

On conserve les mêmes valeurs détaillées d'hyperparamètres que dans Q2 :

$$\alpha_6 = \alpha$$

$$N_6 = N$$

Le tableau suivant présente les résultats MAE obtenus lors de cette nouvelle expérience.

TABLE 3 – Tableau MAE supplémentaire du modèle linéaire

Itérations \ α	.001	.002	.004	.006	.008	.01	.02	.03	.05	.07	.1	.15	.2	.25	.3
100	.1911	.1688	.1426	.1300	.1201	.1123	.1098	.1044	.0928	.0822	.0688	.0515	.0390	.0300	.0285
500	.1360	.1125	.1098	.1044	.0985	.0928	.0689	.0516	.0302	.0276	.0273	.0274	.0274	.0273	.0272
1000	.1125	.1098	.0985	.0874	.0775	.0689	.0392	.0286	.0273	.0274	.0274	.0272	.0271	.0269	.0268
5000	.0928	.0689	.0393	.0286	.0271	.0273	.0274	.0272	.0269	.0267	.0263	.0256	.0250	.0244	.0239
10000	.0689	.0393	.0271	.0274	.0274	.0274	.0271	.0268	.0263	.0257	.0250	.0239	.0230	.0221	.0214

Performance selon alpha :

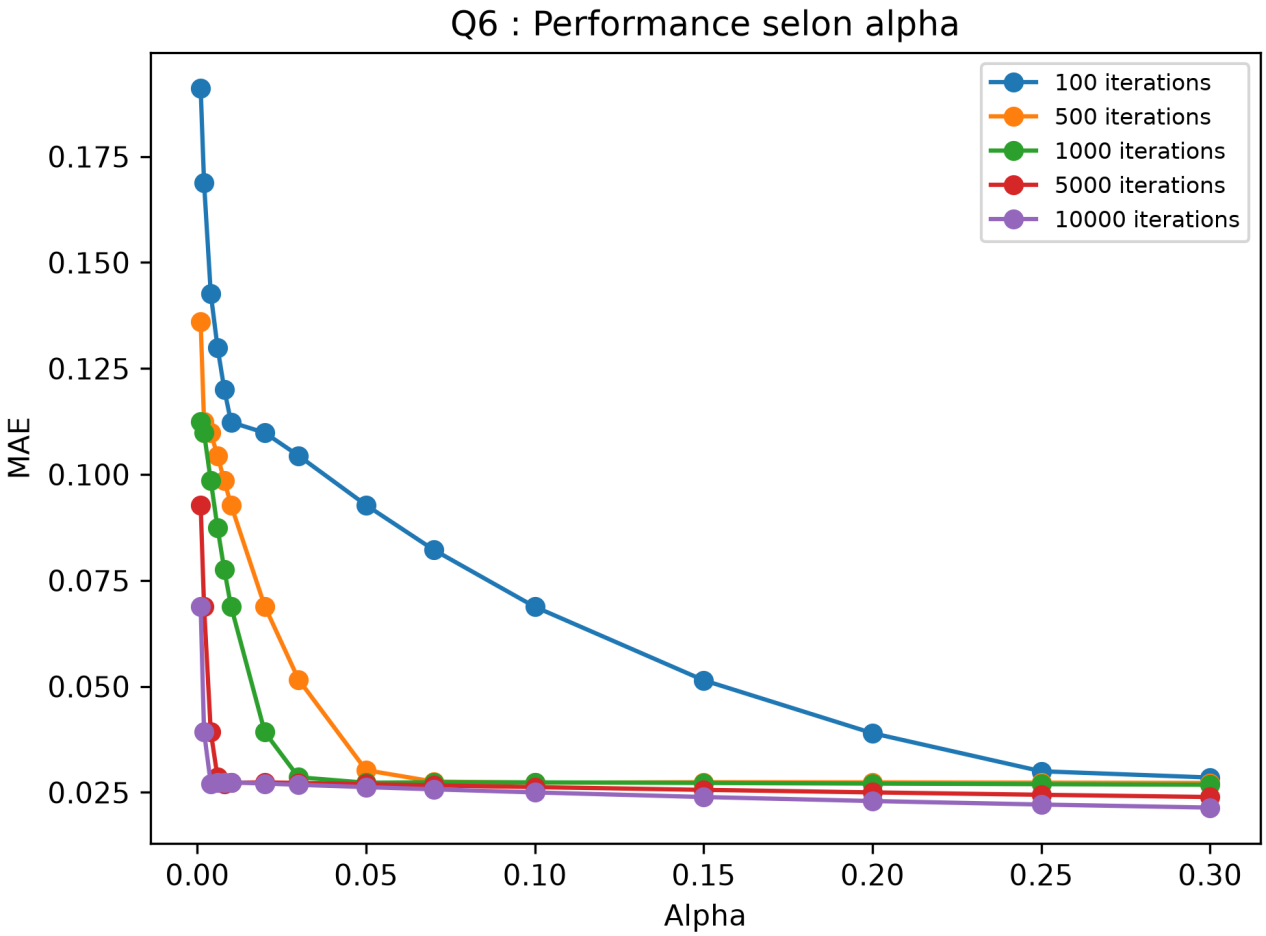


FIGURE 3 – MAE selon alpha pour différents nombres d'itérations

Performance selon les itérations :

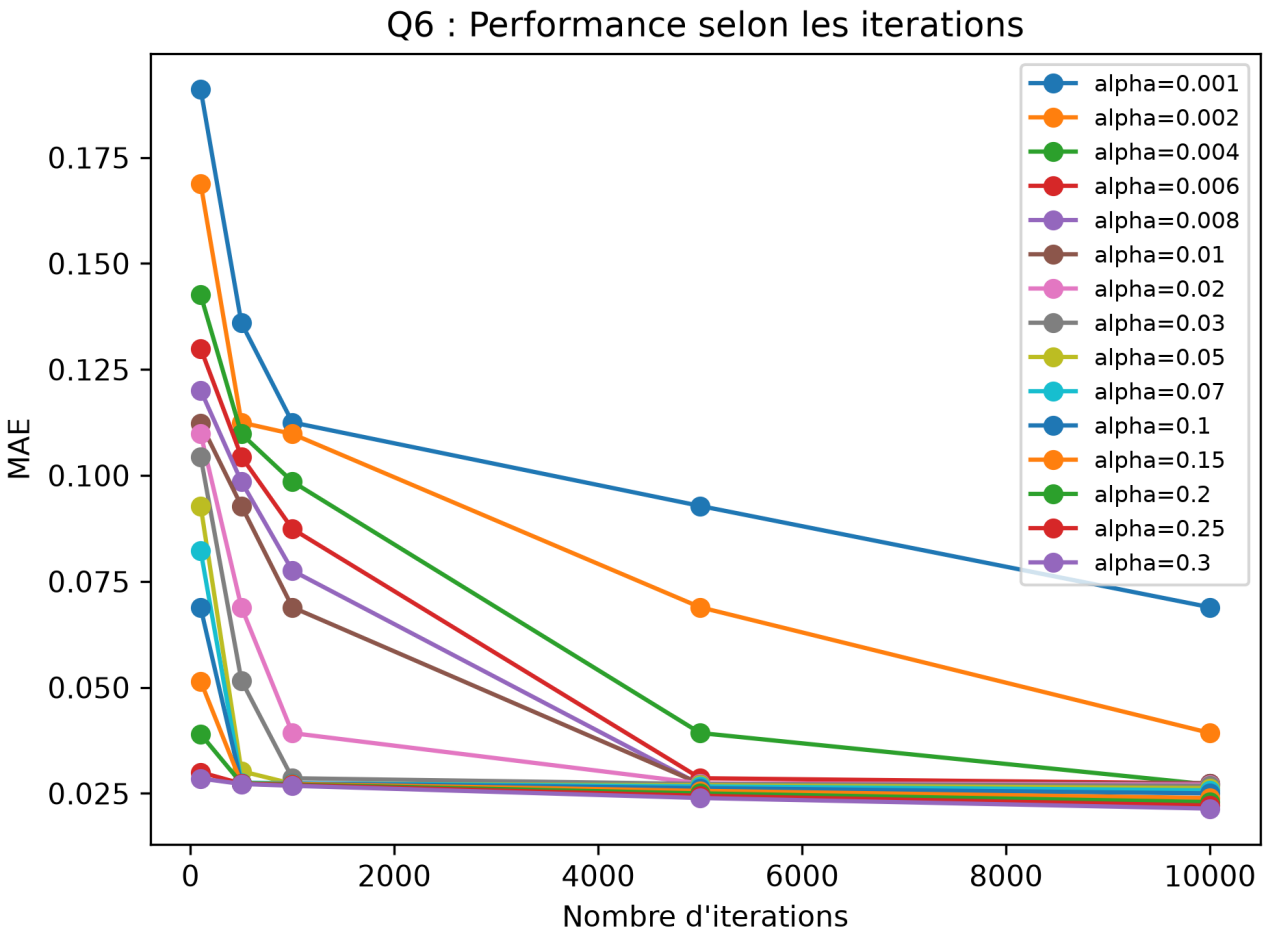


FIGURE 4 – MAE selon le nombre d'itérations

3.7 Q7 : Anomalie du prétraitement

Les variables sont divisées par des constantes fixes :

$$age/100, \qquad km/150, \qquad y/100$$

Cette transformation permet de travailler avec des valeurs plus petites.

Cependant, il ne s'agit pas d'une normalisation complète comme la normalisation Min-Max ou la standardisation.

Les variables ne sont pas centrées et leur dispersion n'est pas nécessairement identique.

3.8 Q8 : Nouvelle initialisation

On initialise les paramètres aléatoirement :

$$\theta_0 \sim \mathcal{U}(-0.7, 0.7)$$

On utilise :

$$\alpha = 0.01, \qquad N = 10000$$

La MAE obtenue est :

$$\boxed{MAE = 0.01788718}$$

Cette expérience montre que l'initialisation des paramètres peut influencer le résultat de l'apprentissage.

4 Partie 2 : Modèle quadratique

4.1 Q9 : Matrice du modèle quadratique

On construit un modèle quadratique contenant les carrés et les produits croisés des variables.

Le modèle est :

$$\begin{aligned} y = \theta_1 x_1^2 + \theta_2 x_2^2 + \theta_3 x_3^2 \\ + \theta_4 x_1 x_2 + \theta_5 x_1 x_3 + \theta_6 x_2 x_3 \\ + \theta_7 x_1 + \theta_8 x_2 + \theta_9 x_3 + \theta_{10} \end{aligned}$$

Avec :

$$x_1 = \frac{age}{100}, \quad x_2 = \frac{puissance}{10}, \quad x_3 = \frac{km}{150}$$

La matrice quadratique obtenue est :

$$X_2 = \begin{bmatrix} 0.3600 & 0.1600 & 0.5378 & 0.2400 & 0.4400 & 0.2933 & 0.60 & 0.40 & 0.7333 & 1 \\ 0.2304 & 0.4900 & 0.3600 & 0.3360 & 0.2880 & 0.4200 & 0.48 & 0.70 & 0.6000 & 1 \\ 0.0144 & 0.1600 & 0.0178 & 0.0480 & 0.0160 & 0.0533 & 0.12 & 0.40 & 0.1333 & 1 \\ 0.0900 & 0.2500 & 0.0900 & 0.1500 & 0.0900 & 0.1500 & 0.30 & 0.50 & 0.3000 & 1 \end{bmatrix}$$

4.2 Q10 : Initialisation des paramètres

Les dix paramètres sont initialisés aléatoirement dans l'intervalle $[-0.7, 0.7]$:

$$\theta_0 \sim \mathcal{U}(-0.7, 0.7)$$

Les valeurs obtenues par Python sont :

$$\begin{aligned} \theta_0 = [&0.46542, -0.40273, -0.44545, -0.44323, \\ &-0.27406, 0.03466, -0.09528, -0.29228, \\ &0.15659, -0.50471] \end{aligned}$$

Cette initialisation permet de commencer l'apprentissage avec des paramètres aléatoires.

4.3 Q11 : Performance du modèle quadratique

On applique le gradient descendant au modèle quadratique en utilisant les mêmes valeurs d'hyperparamètres que pour le modèle linéaire.

Le tableau suivant présente la MAE obtenue.

TABLE 4 – MAE du modèle quadratique

Itérations \ α	.001	.002	.004	.006	.008	.01	.02	.03	.05	.07	.1	.15	.2	.25	.3
100	1.0280	.8512	.5857	.4058	.2840	.2294	.1519	.1314	.1005	.0781	.0550	.0315	.0188	.0119	.0080
500	.4887	.2305	.1525	.1314	.1152	.1007	.0553	.0318	.0122	.0067	.0041	.0018	.0008	.0004	.0003
1000	.2306	.1526	.1152	.0882	.0697	.0554	.0192	.0083	.0041	.0022	.0008	.0003	.0002	.0002	.0002
5000	.1007	.0554	.0193	.0083	.0056	.0041	.0008	.0003	.0002	.0002	.0001	.0001	.0001	.0001	.00005
10000	.0554	.0193	.0056	.0030	.0016	.0008	.0002	.0002	.0001	.0001	.00008	.00005	.00003	.00002	.00001

4.4 Q12 : Comparaison des modèles selon alpha

On compare les performances des deux modèles en fonction du taux d'apprentissage avec 10000 itérations.

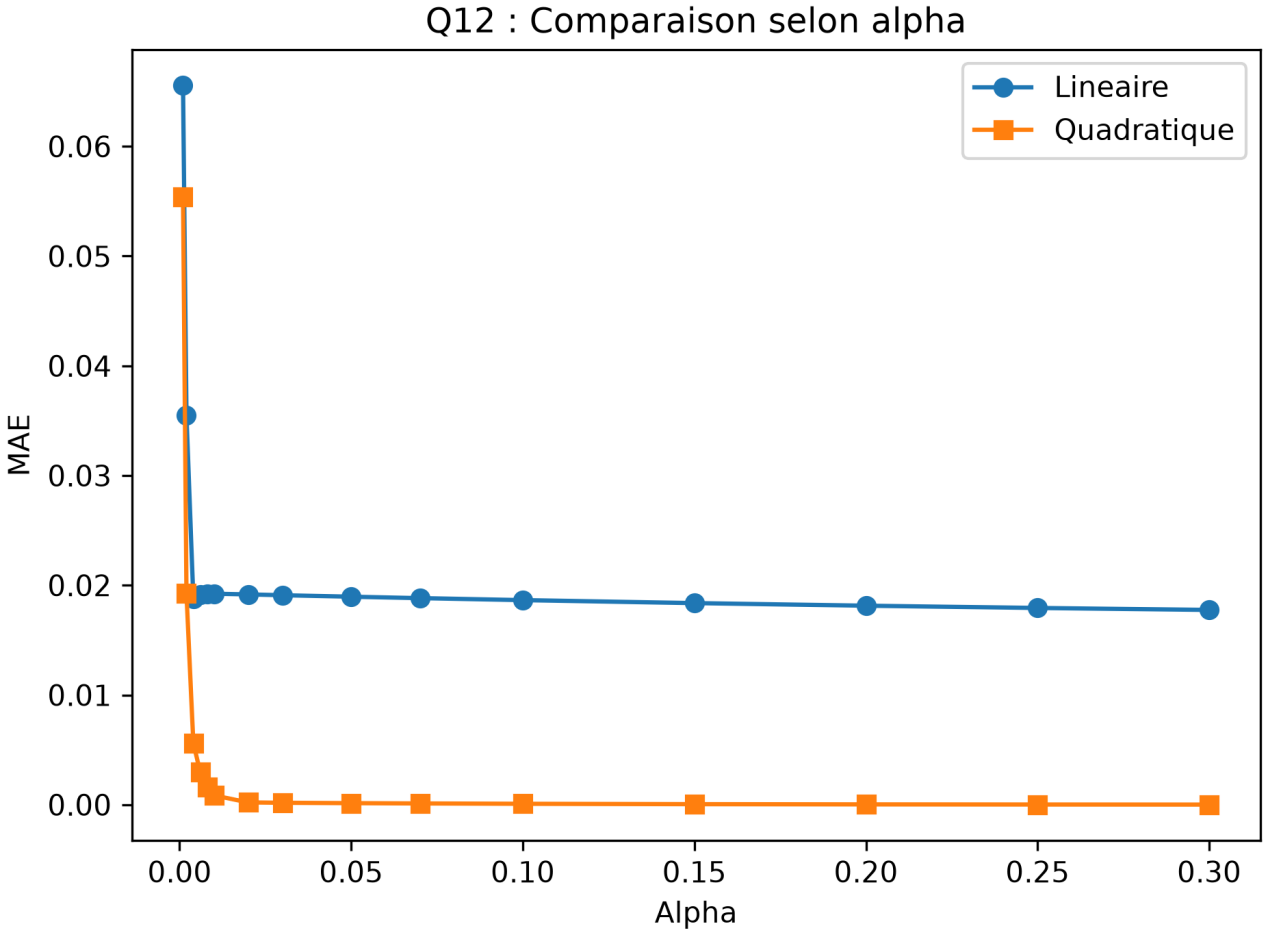


FIGURE 5 – Comparaison des modèles linéaire et quadratique selon alpha

On remarque que le modèle quadratique obtient une MAE plus faible pour les valeurs d'alpha testées dans cette expérience.

Il possède davantage de paramètres et peut donc représenter des relations plus complexes entre les variables.

4.5 Q13 : Comparaison selon le nombre d'itérations

On compare les deux modèles en fonction du nombre d'itérations avec :

$\alpha = 0.002$

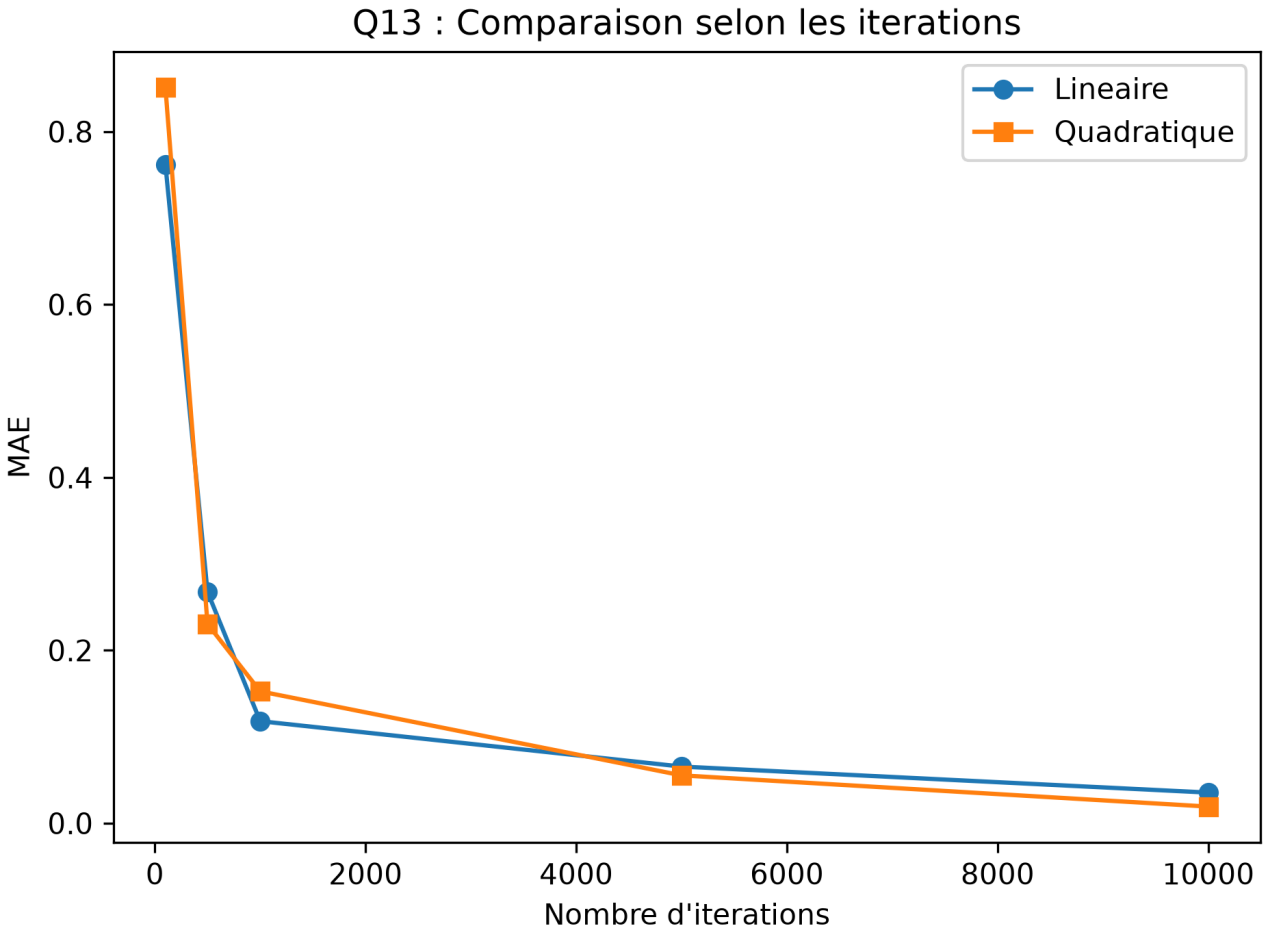


FIGURE 6 – Comparaison des modèles selon le nombre d'itérations

Ce graphique permet d'étudier l'évolution de la MAE des deux modèles lorsque le nombre d'itérations augmente.

5 Remarques et observations

- **Q1 :** Les paramètres sont initialisés aléatoirement entre -0.7 et 0.7. Le gradient descendant met à jour ces paramètres à chaque itération.
- **Q2 :** Le nombre de valeurs de alpha a été augmenté afin d'étudier plus précisément son influence.
- **Q3 :** La MAE et la MSE diminuent généralement avec l'augmentation du nombre d'itérations et du taux d'apprentissage, tant que l'algorithme reste stable.
- **Q4 et Q5 :** Les graphiques montrent l'influence du taux d'apprentissage et du nombre d'itérations. Un alpha trop élevé peut entraîner une divergence.
- **Q6 :** Une nouvelle expérience est réalisée avec une autre initialisation aléatoire. Les résultats peuvent donc être différents de ceux de Q3.
- **Q7 :** Les variables sont divisées par des constantes fixes. Cette transformation réduit leur échelle, mais ne correspond pas à une normalisation complète.
- **Q8 :** Une initialisation aléatoire donne une MAE de 0.01788718 après 10000 itérations.

— **Q9 et Q10 :** Le modèle quadratique ajoute des termes de degré deux et des produits croisés. Ses dix paramètres sont initialisés aléatoirement.
— **Q11 :** La MAE du modèle quadratique diminue fortement lorsque le nombre d'itérations et alpha augmentent.
— **Q12 et Q13 :** Le modèle quadratique présente une erreur plus faible dans cette expérience. Toutefois, il faut rester prudent, car le jeu de données contient seulement quatre observations.

6 Conclusion

Ce TP a permis d'implémenter le gradient descendant pour deux modèles de régression : linéaire et quadratique.

L'étude des hyperparamètres a montré l'importance du choix du taux d'apprentissage et du nombre d'itérations dans la convergence de l'algorithme.

L'initialisation aléatoire permet également d'étudier l'influence des valeurs initiales sur l'apprentissage.

Enfin, le modèle quadratique obtient une erreur plus faible dans les expériences réalisées. Cependant, avec seulement quatre observations et dix paramètres, il existe un risque important de surapprentissage. Une évaluation sur davantage de données serait nécessaire pour confirmer sa capacité de généralisation.